

Entrega Final: Ecosistema de Automatización IA Autónomo

Caso: "Recepción Inteligente" de una clínica. Una consulta de paciente se clasifica y responde con IA, pasa por aprobación humana (HITL) y se envía, todo orquestado en n8n.




Figura 1. Arquitectura de dos workflows con punto de interrupción humana (HITL) y ruta de error.

1. Flujo de extremo a extremo

El **Workflow 1** se dispara por agenda, trae de Notion las consultas en estado **Pendiente**, las pasa por la IA (Gemini) que clasifica y redacta un borrador apoyada en la base de conocimiento (RAG), guarda el

resultado y deja la consulta en **En_revisión**, avisando al equipo por Slack. El sistema se **detiene** ahí. El **Workflow 2** vigila las consultas aprobadas: solo cuando un humano tilda el Checkbox **Aprobado**, envía la respuesta al paciente por Gmail y marca la consulta como **Enviado**.

2. Tecnologías integradas

Capa	Tecnología	Rol en el sistema
Orquestador	n8n	Flujo principal (2 workflows)
Base de datos	Notion	Memoria y registro por estados, con relación entre tablas
Procesamiento IA	Gemini *	Clasifica y redacta con prompt estructurado + RAG
Canal de salida	Gmail + Slack	Gmail al paciente; Slack para la revisión interna

* El rubric admite OpenAI o Claude; por falta de acceso a sus APIs pagas se usó el módulo equivalente de Gemini. La arquitectura evaluada es idéntica; solo cambia el proveedor del LLM.

3. Requisitos de arquitectura cumplidos

Requisito	Cómo se cumple
Disparo y entrega sin intervención manual	Schedule + filtro por Estado; la IA procesa y deja todo listo de forma automática
Trigger inteligente (sin malgastar operaciones)	Notion Get Many filtrado a Estado = Pendiente: no lee registros ya procesados
Ruta de error / resiliencia	Continue-on-fail en el nodo de IA -> Estado = Error y detalle en Log_error
Punto de validación humana (HITL)	Pausa en En_revisión; el envío solo ocurre si el Checkbox Aprobado = true
Nodos nombrados y variables dinámicas	Cada nodo tiene nombre descriptivo; los IDs y textos se mapean por expresión, sin hardcodear
Sin bucles infinitos	Al avanzar el Estado (Procesado/Enviado), la fila deja de cumplir el filtro y no se reprocesa

4. Análisis operativo y de costos

El ecosistema corre con un **costo de infraestructura de US\$0**: n8n (prueba/self-host), Notion (plan free), Gemini (capa gratuita) y Gmail/Slack (gratis). En términos de operaciones de n8n, procesar una consulta consume aproximadamente **1 ejecución en el Workflow 1 y 1 en el Workflow 2**; el sondeo cada 5 minutos se mantiene liviano gracias al filtro por Estado, que evita leer registros ya resueltos. Si en producción se migrara a una API paga, el modelo de optimización de la Pre-Entrega 6 (limitar Max Tokens, prompt caching del prefijo estático y procesamiento por lotes) reduciría el costo del LLM hasta cerca del 90%.

5. Estados del sistema (memoria)

Estado	Significado	Quién actúa
Pendiente	Consulta nueva sin procesar	Dispara el Workflow 1
En_revisión	Borrador listo, espera aprobación	Humano (HITL)
Aprobado (true)	Validado para enviar	Dispara el Workflow 2
Enviado	Respuesta entregada al paciente	Cierra el ciclo
Error	Falló una API; queda registrado	Revisión / reintento